

ANALISE DE RISCO DE CREDITO

Comparacao de Modelos de Machine Learning

Dataset: UCI Credit Card Default | 30,000 observacoes | 30 features



Gerado em: 02/06/2026

Este relatorio apresenta analise completa de risco de credito com ML.
Abrange EDA, feature engineering, comparacao de 5 modelos, k-fold,
testes estatisticos, calibracao, interpretabilidade SHAP e simulador.

Fase 1 - Análise Exploratoria


Distribuição da Variável Alvo

Análise do Desbalanceamento de Classes



Mapa de Correlação


Mapa de Correlação entre Variáveis



Distribuição das Variáveis


Credit Risk Analysis v2 - Relatório Completo

Distribuição das Variáveis Numéricas




Boxplots - Outliers

Boxplots: Variáveis Numéricas por Status de Inadimplência




Análise de Vies por Faixa Etária

Taxa de Inadimplência por Faixa Etária (Análise de Viés)



Fase 2 - Engenharia de Atributos


Impacto das Features Engenhadas



Fase 3 - Comparacao de Modelos


Curvas ROC e Precision-Recall

Curvas ROC e Precision-Recall — Comparação de Modelos




Matrizes de Confusao

Matrizes de Confusão por Modelo



Fase 4 - Otimizacao


AUC Antes vs Depois



Fase 5 - Validacao K-Fold


Distribuição AUC por Fold

Validação Cruzada Estratificada



Fase 6 - Testes Estatísticos


p-values Paired t-test e McNemar



Fase 7 - Calibração


Curvas de Calibração

Curvas de Calibração — Bruto vs. Calibrado (Isotônico)




Fase 8 - Interpretabilidade


Coeficientes - Logística




Feature Importance - RF



SHAP Beeswarm - XGBoost




SHAP Importancia Media




Fase 9 - Perfis Individuais


SHAP Waterfall - Perfil Individual



SHAP Waterfall - Perfil Individual


Cliente B — Médio Risco | $P(\text{default}) = 41.4\%$ | MÉDIO RISCO

SHAP Waterfall - Perfil Individual

Cliente C — Alto Risco | $P(\text{default}) = 95.6\%$ | ALTO RISCO $f(x) = 3.083$ 

Conclusões

Resumo Final de Performance



Tabelas de Resultados

Tabela 1: Metricas dos Modelos

Modelo	Accuracy	Precision	Recall	F1	ROC AUC	PR AUC	Log Loss	Brier
Baseline	0.7788	0.0000	0.0000	0.0000	0.5000	0.2212	7.9717	0.2212
Logística	0.7015	0.3851	0.5863	0.4649	0.6992	0.4436	0.5921	0.2004
Random Forest	0.7978	0.5514	0.4604	0.5018	0.7545	0.5108	0.4778	0.1510
XGBoost	0.7907	0.5324	0.4393	0.4814	0.7445	0.5030	0.4925	0.1536
LightGBM	0.7972	0.5520	0.4401	0.4897	0.7645	0.5282	0.4567	0.1456

Tabela 2: Validacao K-Fold

index	Logística	Random Forest	XGBoost	LightGBM
Fold 1	0.7314	0.7703	0.7614	0.7763
Fold 2	0.7512	0.7877	0.7772	0.7952
Fold 3	0.7163	0.7601	0.7513	0.7584
Fold 4	0.7482	0.7698	0.7636	0.7769
Fold 5	0.7228	0.7579	0.7487	0.7665
Fold 6	0.7540	0.7725	0.7557	0.7806
Fold 7	0.7390	0.7805	0.7641	0.7870
Fold 8	0.7380	0.7783	0.7706	0.7819
Fold 9	0.7392	0.7695	0.7530	0.7779
Fold 10	0.7426	0.7627	0.7466	0.7696
Média	0.7383	0.7709	0.7592	0.7770
Desvio	0.0114	0.0089	0.0094	0.0099

Tabela 3: Calibracao (Brier Score)

Modelo	Brier Bruto	Brier Calibrado	Melhoria
Random Forest	0.1510	0.1396	0.0114
XGBoost	0.1550	0.1430	0.0120
LightGBM	0.1451	0.1382	0.0069

Tabela 4: Testes Estatisticos

Comparação	AUC médio	t-statistic	p-value	Resultado
Random Forest vs	0.0117	8.7730	0.0000	OK Sig.
Random Forest vs	0.0327	10.9366	0.0000	OK Sig.
XGBoost vs Light	-0.0178	-9.1533	0.0000	OK Sig.
XGBoost vs Logís	0.0209	5.6831	0.0003	OK Sig.
LightGBM vs Logí	0.0388	15.0316	0.0000	OK Sig.

Tabela 5: Otimizacao de Hiperparametros

Modelo	AUC Antes	AUC Depois	Ganho
Random Forest	0.7545	0.7556	0.0011
XGBoost	0.7445	0.7438	-0.0007
LightGBM	0.7645	0.7646	0.0001

Conclusões - 7 Questões de Pesquisa

1. ML supera Regressão Logística?

SIM. O melhor modelo (LightGBM) obteve AUC=0.7645 e F1=0.5018, contra AUC=0.6992 e F1=0.4649 da Regressão Logística. Ganho absoluto no AUC: +0.0653.

2. Qual modelo apresenta melhor capacidade preditiva?

LightGBM: AUC=0.7645 no conjunto de teste. Em K-Fold, LightGBM obteve média 0.7770 ± 0.0099 .

3. O ganho de performance é estatisticamente significativo?

SIM em 5/5 comparações (paired t-test, $\alpha=0.05$). Modelos ensemble são significativamente superiores à Regressão Logística.

4. O modelo é estável em diferentes amostras?

SIM. LightGBM apresentou desvio padrão de 0.0099 em 10 folds, indicando boa estabilidade. Desvio < 0.01 é considerado excelente.

5. As probabilidades previstas são confiáveis?

SIM. A calibração isotônica melhorou o Brier Score em todos os modelos testados. Sem calibração, os modelos tendem a superestimar ou subestimar as probabilidades nos extremos.

6. Quais variáveis mais influenciam a inadimplência?

Segundo SHAP (XGBoost), as 5 features mais impactantes são: ['mean_delay', 'max_delay', 'MARRIAGE', 'PAY_0', 'total_bill']. Status de pagamento recente (PAY_0, mean_delay) e limite de crédito (LIMIT_BAL) dominam as predições.

7. É possível conciliar performance e interpretabilidade?

SIM. XGBoost com SHAP oferece AUC=0.7645 com explicabilidade total (global via beeswarm + individual via waterfall). A Regressão Logística oferece interpretabilidade máxima mas com custo de ~ 0.0653 de AUC.